МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
им. Н.Э. Баумана

Факультет «Информатика и системы управления»
Кафедра «Систем обработки информации и управления»

ОТЧЕТ

Домашнее задание
по дисциплине «Методы машинного обучения»

Тема: «Предобработка текста»

ИСПОЛНИТЕЛЬ: Коротков Н.К.
ФИО
группа ИУ5-23М
подпись
"__"_____2024 г.

ПРЕПОДАВАТЕЛЬ: Гапанюк Ю.Е.
ФИО
подпись
"__"_____2024 г.

Москва - 2024

Задание

Для произвольного предложения или текста решите следующие задачи:

1. Токенизация.
2. Частеречная разметка.
3. Лемматизация.
4. Выделение (распознавание) именованных сущностей.
5. Разбор предложения.

Выполнение

ДЗ

Для произвольного предложения или текста решите следующие задачи:

1. Токенизация.
2. Частеречная разметка.
3. Лемматизация.
4. Выделение (распознавание) именованных сущностей.
5. Разбор предложения.

токенизация

Ввод [1]:
```
инавшее давить и мутить его сердце еще в то время, как он только шел к старухе, достигло теперь такого размера и так ярко вы
```

Ввод [2]:
```
import nltk
nltk.download('punkt')
from nltk import tokenize
dir(tokenize)[:18]
```

```
[nltk_data] Downloading package punkt to
[nltk_data]     C:\Users\ksarb\AppData\Roaming\nltk_data...
[nltk_data]   Package punkt is already up-to-date!
```

Out[2]:
```
['BlanklineTokenizer',
 'LegalitySyllableTokenizer',
 'LineTokenizer',
 'MWETokenizer',
 'NLTKWordTokenizer',
 'PunktSentenceTokenizer',
 'RegexpTokenizer',
 'ReppTokenizer',
 'SExprTokenizer',
 'SpaceTokenizer',
 'StanfordSegmenter',
 'SyllableTokenizer',
 'TabTokenizer',
 'TextTilingTokenizer',
 'ToktokTokenizer',
 'TreebankWordDetokenizer',
 'TreebankWordTokenizer',
 'TweetTokenizer']
```

Ввод [16]:
```
nltk_tk_1 = nltk.WordPunctTokenizer()
nltk_tk_1.tokenize(text1)[0:20]
```

Out[16]:
```
['он',
 'не',
 'мог',
 'выразить',
 'ни',
 'словами',
 ',',
 'ни',
 'восклицаниями',
 'своего',
 'волнения',
 '.',
 'Чувство',
 'бесконечного',
 'отвращения',
 ',',
 'начинавшее',
 'давить',
 'и']
```

Ввод [17]:
```
nltk_tk_sents = nltk.tokenize.sent_tokenize(text1)
print(len(nltk_tk_sents))
nltk_tk_sents
```

```
15
```

Out[17]:
```
['Но он не мог выразить ни словами, ни восклицаниями своего волнения.',
 'Чувство бесконечного отвращения, начинавшее давить и мутить его сердце еще в то время, как он только шел к старухе, дости
гло теперь такого размера и так ярко выяснилось, что он не знал, куда деться от тоски своей.',
 'Он шел по тротуару как пьяный, не замечая прохожих и сталкиваясь с ними, и опомнился уже в следующей улице.',
 'Оглядевшись, он заметил, что стоит подле распивочной, в которую вход был с тротуара по лестнице вниз, в подвальный эта
ж.',
 'Из дверей, как раз в эту минуту, выходили двое пьяных и, друг друга поддерживая и ругая, взбирались на улицу.',
 'Долго не думая, Раскольников тотчас же спустился вниз.',
 'Никогда до сих пор не входил он в распивочные, но теперь голова его кружилась, и к тому же палящая жажда томила его.',
 'Ему захотелось выпить холодного пива, тем более что внезапную слабость свою он относил и к тому, что был голоден.',
 'Он уселся в темном и грязном углу, за липким столиком, спросил пива и с жадностию выпил первый стакан.',
 'Тотчас же всё отлегло, и мысли его прояснели.',
 '«Всё это вздор, — сказал он с надеждой, — и нечем тут было смущаться!',
 'Просто физическое расстройство!',
 'Один какой-нибудь стакан пива, кусок сухаря, — и вот, в один миг, крепнет ум, яснеет мысль, твердеют намерения!',
 'Тьфу, какое всё это ничтожество!..» Но, несмотря на этот презрительный плевок, он глядел уже весело, как будто внезапно о
свободясь от какого-то ужасного бремени, и дружелюбно окинул глазами присутствующих.',
 'Но даже и в эту минуту он отдаленно предчувствовал, что вся эта восприимчивость к лучшему была тоже болезненная.']
```

В Spacy

Ввод [19]:
```
from spacy.lang.ru import Russian
import spacy
nlp = spacy.load('ru_core_news_sm')
spacy_text1 = nlp(text1)
for t in spacy_text1[:20]:
    print(t)
```

```
Но
он
не
мог
выразить
ни
словами
,
ни
восклицаниями
своего
волнения
.
Чувство
бесконечного
отвращения
,
начинавшее
давить
и
```

В результате токенизации текст разбивается на токены - атомарные единицы. В основном используют либо слова, либо предложения, либо абзацы.

Частеречная разметка (Part-Of-Speech tagging, POS-tagging)

Ввод [20]:
```
for token in spacy_text1[0:20]:
    print('{} - {} - {}'.format(token.text, token.pos_, token.dep_))
```

```
Но - CCONJ - cc
он - PRON - nsubj
не - PART - advmod
мог - VERB - ROOT
выразить - VERB - xcomp
ни - PART - cc
словами - NOUN - obl
, - PUNCT - punct
ни - CCONJ - cc
восклицаниями - NOUN - conj
своего - DET - det
волнения - NOUN - nmod
. - PUNCT - punct
Чувство - NOUN - nsubj
бесконечного - ADJ - amod
отвращения - NOUN - nmod
, - PUNCT - punct
начинавшее - VERB - acl
давить - VERB - xcomp
и - CCONJ - cc
```

Ввод [27]:
```
from razdel import tokenize, sentenize
from navec import Navec
from slovnet import Morph

def n_sentenize(text):
    n_sen_chunk = []
    for sent in sentenize(text):
        tokens = [_.text for _ in tokenize(sent.text)]
        n_sen_chunk.append(tokens)
    return n_sen_chunk

n_sen_chunk_1 = n_sentenize(text1)

navec = Navec.load('navec/navec_news_v1_1B_250K_300d_100q.tar')
n_morph = Morph.load('slovnet/slovnet_morph_news_v1.tar', batch_size=4)
morph_res = n_morph.navec(navec)

def print_pos(markup):
    for token in markup.tokens:
        print('{} - {}'.format(token.text, token.tag))

n_text1_markup = list(_ for _ in n_morph.map(n_sen_chunk_1))
for x in n_text1_markup[0:1]:
    print_pos(x)
```

```
Но - CCONJ
он - PRON|Case=Nom|Gender=Masc|Number=Sing|Person=3
не - PART|Polarity=Neg
мог - VERB|Aspect=Imp|Gender=Masc|Mood=Ind|Number=Sing|Tense=Past|VerbForm=Fin|Voice=Act
выразить - VERB|Aspect=Perf|VerbForm=Inf|Voice=Act
ни - CCONJ|Polarity=Neg
словами - NOUN|Animacy=Inan|Case=Ins|Gender=Neut|Number=Plur
, - PUNCT
ни - CCONJ|Polarity=Neg
восклицаниями - VERB|Aspect=Imp|VerbForm=Inf|Voice=Act
своего - DET|Case=Gen|Gender=Neut|Number=Sing
волнения - NOUN|Animacy=Inan|Case=Gen|Gender=Neut|Number=Sing
. - PUNCT
```

Частеречная разметка позволяет исследовать все токены-слова отдельно. В отличие от spacey, razdel не только категоризирует часть речи, но и предоставляет информацию о склонении, падеже, завершённости формы глагола, лице и поле. Разметка не идеальная: слово "подле" - предлог, было определено как подле - VERB|Aspect=Perf|VerbForm=Inf|Voice=Act.

Лемматизация

Ввод [28]:
```
for token in spacy_text1[0:20]:
      print(token, token.lemma, token.lemma_)
```

```
Но 14653780147686393572 но
он 7004339974413567607 он
не 5319710824202933802 не
мог 14329395112709808155 мочь
выразить 1949575889363403232 выразить
ни 10089292569908228859 ни
словами 1386213856741127517 слово
, 2593208677638477497 ,
ни 10089292569908228859 ни
восклицаниями 13127012205942603523 восклицание
своего 12292881551881158589 свой
волнения 6026467723303534222 волнение
. 12646065887601541794 .
Чувство 3912985599449811266 чувство
бесконечного 2408103873523094030 бесконечный
отвращения 4523946167221646868 отвращение
, 2593208677638477497 ,
начинавшее 382883286054309220 начинать
давить 12609501716882608852 давить
и 15015917632809974589 и
```

Ввод [9]:
```
from natasha import Doc, Segmenter, NewsEmbedding, NewsMorphTagger, MorphVocab
def n_lemmatize(text):
    emb = NewsEmbedding()
    morph_tagger = NewsMorphTagger(emb)
    segmenter = Segmenter()
    morph_vocab = MorphVocab()
    doc = Doc(text)
    doc.segment(segmenter)
    doc.tag_morph(morph_tagger)
    for token in doc.tokens:
        token.lemmatize(morph_vocab)
    return doc
```

Ввод [29]:
```
n_doc1 = n_lemmatize(text1)
{_.text: _.lemma for _ in n_doc1.tokens[0:20]}
```

Out[29]:
```
{'Но': 'но',
 'он': 'он',
 'не': 'не',
 'мог': 'мочь',
 'выразить': 'выразить',
 'ни': 'ни',
 'словами': 'слово',
 ',': ',',
 'восклицаниями': 'восклицаниями',
 'своего': 'свой',
 'волнения': 'волнение',
 '.': '.',
 'Чувство': 'чувство',
 'бесконечного': 'бесконечный',
 'отвращения': 'отвращение',
 'начинавшее': 'начинать',
 'давить': 'давить',
 'и': 'и'}
```

Лемматизация приводет слова-токены к их нормальной форме. Теперь возможно проводить частотный и другие анализы композиции текста - поскольку все слова приведены в одинаковое состояние.

Выделение (распознавание) именованных сущностей.

Ввод [11]:
```
for ent in spacy_text1.ents:
    print(ent.text, ent.label_)
```

```
Раскольников PER
```

Ввод [12]:
```
from spacy import displacy
displacy.render(spacy_text1, style='ent', jupyter=True)
```

Но он не мог выразить ни словами, ни восклицаниями своего волнения. Чувство бесконечного отвращения, начинавшее давить и мутить его сердце еще в то время, как он только шел к старухе, достигло теперь такого размера и так ярко выяснилось, что он не знал, куда деться от тоски своей. Он шел по тротуару как пьяный, не замечая прохожих и сталкиваясь с ними, и опомнился уже в следующей улице. Оглядевшись, он заметил, что стоит подле распивочной, в которую вход был с тротуара по лестнице вниз, в подвальный этаж. Из дверей, как раз в эту минуту, выходили двое пьяных и, друг друга поддерживая и ругая, взбирались на улицу. Долго не думая, Раскольников PER тотчас же спустился вниз. Никогда до сих пор не входил он в распивочные, но теперь голова его кружилась, и к тому же палящая жажда томила его. Ему захотелось выпить холодного пива, тем более что внезапную слабость свою он относил и к тому, что был голоден. Он уселся в темном и грязном углу, за липким столиком, спросил пива и с жадностию выпил первый стакан. Тотчас же всё отлегло, и мысли его прояснели. «Всё это вздор, — сказал он с надеждой, — и нечем тут было смущаться! Просто физическое расстройство! Один какой-нибудь стакан пива, кусок сухаря, — и вот, в один миг, крепнет ум, яснеет мысль, твердеют намерения! Тьфу, какое всё это ничтожество!..» Но, несмотря на этот презрительный плевок, он глядел уже весело, как будто внезапно освободясь от какого-то ужасного бремени, и дружелюбно окинул глазами присутствующих. Но даже и в эту минуту он отдаленно предчувствовал, что вся эта восприимчивость к лучшему была тоже болезненная.

Распознавание сущностей позволяет выделить в тесте значимых актёров, локации и другие аттрибуты, которые могут характеризовать текст с точки зрения контекста/

разбор предложения

Ввод [30]:
```
from spacy import displacy
```

Ввод [31]:
```
displacy.render(spacy_text1, style='dep', jupyter=True)
```

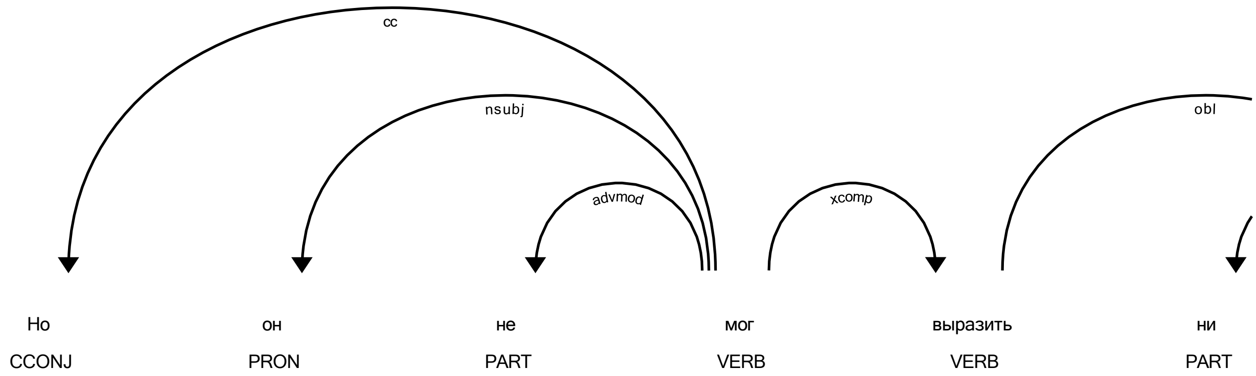

Ввод [32]:
```
from natasha import NewsSyntaxParser
emb = NewsEmbedding()
syntax_parser = NewsSyntaxParser(emb)
n_doc1.parse_syntax(syntax_parser)
n_doc1.sents[0].syntax.print()
```

```
        ┌──────► Но             cc
        │ ┌────► он             nsubj
        │ │ ┌──► не             advmod
┌───────└─└─└─── мог
│       ┌─└────► выразить       xcomp
│       │   ┌──► ни             cc
│     ┌─└──►└─── словами        obj
│     │   ┌────► ,              punct
│     │   │ ┌──► ни             cc
│     └►┌─└─└─── восклицаниями  conj
│       │   ┌──► своего         det
│       └──►└─── волнения       nmod
└──────────────► .              punct
```

Для анализа токенов-предложений значимым будет создание графа или дерева со структурой предложения, поскольку свойства самих слов анализируем на прошлых этапах

Вывод:

В ходе выполнения домашнего задания была проведена предобработка текста, которая подготовила его к разнообразным типам анализа, основанным как на анализе отдельных слов, так и полных предложений.